

Diagnóstico inicial del challenge de dirección intradía

Inspección de datos, formulación cuantitativa e hipótesis de investigación

Objetivo. Predecir la dirección predominante del retorno entre 14:00 y 16:00 a partir de 53 retornos de 5 minutos observados entre 09:30 y 14:00. El target reod toma valores -1, 0 o +1 según el retorno final sea menor a -25 bps, esté entre -25 y +25 bps, o supere +25 bps.

1. Lo que muestran los CSV

Archivo / estructura	Training	Test
Observaciones	843,299	885,799
Columnas input	56	56
Días únicos	503	505
Equities únicas	1,829	1,894
Variables temporales	r0-r52 (53)	r0-r52 (53)
NaN en celdas r0:r52	10.77%	2.98%
Filas con >=1 NaN	28.74%	12.64%
Filas con 53 NaN	1,996	400
Ceros entre retornos observados	23.49%	17.94%

Separación OOS verificada. No existe intersección entre los días, equities ni IDs de training y test. Esto impide depender de la memorización de identificadores y obliga a generalizar simultáneamente a activos no vistos y a otro bloque temporal.

Distribución del target de training: -1 = 30.08%, 0 = 41.20%, +1 = 28.72%. Por ello, predecir siempre la clase 0 ya produce ~41.20% de accuracy en training. El benchmark reportado de 41.74% debe compararse contra este majority-class baseline, no sólo contra 33%.

Distribution shift visible: el patrón de missingness cambia de forma marcada entre train y test (10.77% vs. 2.98% de NaN). Esto confirma que la robustez fuera de muestra debe ser parte central del diseño. Además, NaN y retorno igual a cero deben tratarse como estados distintos hasta entender mejor su mecanismo.

2. Formulación cuantitativa

La unidad natural no es una fila tabular aislada, sino un panel Equity x Day x Intraday Time. Para cada equity i y día d se observa una trayectoria $X(i,d) = [r_0, \dots, r_{52}]$ y se busca estimar $P(\text{reod} = -1, 0, +1)$. Como cada día contiene muchas equities simultáneamente, el dataset permite construir información cross-sectional sin conocer los tickers reales.

Tres bloques de señal candidatos: (1) trayectoria propia del activo: momentum, volatilidad, tendencia, reversals, drawdown y comportamiento reciente; (2) estado de mercado del día: retorno agregado/mediano, breadth y volatilidad cross-sectional; (3) comportamiento relativo: retorno del activo menos un proxy de mercado construido con las equities del mismo día.

Una representación útil sería $r_{\text{rel}}(i,d,t) = r(i,d,t) - M(d,t)$, donde $M(d,t)$ es, por ejemplo, la mediana cross-sectional del retorno en cada intervalo. Esto permite distinguir un movimiento absoluto de un movimiento idiosincrático respecto al mercado.

Pregunta de research: ¿La estructura temporal de la trayectoria intradía de una equity, combinada con su comportamiento relativo al estado cross-sectional del mercado, contiene información suficiente para predecir el régimen direccional de las últimas dos horas en equities y periodos completamente no vistos?

3. Cómo abordar el problema

Primero señal, después complejidad. El objetivo inicial no debe ser escoger una arquitectura sofisticada, sino demostrar si existe señal OOS y de dónde proviene. La validación debe imitar el test real: no usar un random split que mezcle los mismos días/equities entre train y validation.

Etapas	Propósito	Ejemplos
0. Baselines	Fijar el mínimo que debe superar cualquier modelo.	Clase 0; regresión logística sobre r0-r52.
1. Quant features	Detectar señal interpretable antes de deep learning.	Retorno acumulado; 30/60/120m; realized vol; slope; R ² ; drawdown; range; reversals; autocorrelación; missing ratio.
2. Market/relative	Probar si el contexto cross-sectional agrega información.	Market path; breadth; market volatility; relative momentum; relative volatility.
3. Secuencia	Evaluar si la forma completa del path agrega señal.	GRU/LSTM con retornos y máscara de missingness.
4. Attention	Aprender qué tramos intradía importan.	Temporal attention sobre asset + market + relative path + mask.
5. OOS / ablation	Atribuir la mejora a información concreta.	Asset vs Asset+Market vs +Relative vs Attention.

4. Hipótesis de trabajo

H1 - Señal individual: estadísticas de la trayectoria del activo superan al majority-class baseline. H2 - Contexto de mercado: Asset + Market supera Asset-only. H3 - Señal relativa: añadir relative path mejora sobre Asset + Market. H4 - Path dependence: un modelo temporal/attention supera features agregadas al capturar orden, persistencia y cambios de régimen dentro de la sesión.

La originalidad puede venir de la formulación, no de forzar un método. Reinforcement Learning no encaja naturalmente porque no existe una secuencia de acciones que altere el entorno y produzca rewards; es un problema supervisado sequence-to-class. Un modelo de difusión sería defendible sólo como extensión generativa para modelar trayectorias futuras condicionales, pero añade complejidad y no debería preceder a los baselines.

5. Riesgos metodológicos a controlar

Leakage cross-sectional: cualquier feature de mercado del día debe construirse exclusivamente con información disponible hasta las 14:00. Validación: evitar random row split; crear folds que dejen fuera días y equities, idealmente respetando bloques temporales. Missingness: no convertir automáticamente NaN a cero; usar máscara y probar sensibilidad. Métrica: además de accuracy, monitorear balanced accuracy, macro-F1 y matriz de confusión para evitar que la clase 0 domine la evaluación interna.

6. Próximo paso recomendado

Construir primero 00_data_audit_and_problem_definition y 01_eda_and_signal_hypotheses. Antes de entrenar redes, medir empíricamente momentum vs. mean reversion, relación entre ventanas tempranas/recientes y reod, efecto de volatilidad, market breadth, relative momentum y missingness. Sólo después fijar el framework de validación y entrenar el benchmark cuantitativo.

Base documental. Este diagnóstico se construyó a partir de la descripción del challenge proporcionada y de la inspección directa de input_training.csv, output_training_gmEd6Zt.csv, input_test.csv y output_test_random.csv. El output_test_random se interpreta como formato/submission de referencia; no como ground truth del test.