

Reinforcement Learning para Ejecución Óptima

Problemática, Datos e Hipótesis de Modelación

Adrián Vázquez

13 de agosto de 2026

1. Problemática: Ejecución Óptima

El objetivo de la ejecución óptima es ejecutar una orden de gran tamaño equilibrando dos riesgos principales:

Objetivo de Ejecución = Costo por Impacto de Mercado + λ · Riesgo de Inventario

- Ejecutar demasiado rápido puede incrementar el **impacto de mercado** y deteriorar el precio de ejecución.
- Ejecutar demasiado lento mantiene inventario expuesto a **incertidumbre y movimientos adversos del precio**.
- Estrategias como TWAP y VWAP utilizan reglas o trayectorias de ejecución predefinidas.
- Almgren–Chriss formaliza analíticamente el trade-off entre costo de ejecución y riesgo.

Motivación:

Las condiciones de liquidez, volatilidad y volumen cambian durante la sesión. Por ello, una política adaptativa podría ajustar dinámicamente la intensidad de ejecución según el estado observado del mercado.

2. Datos y Representación del Problema

El framework utiliza exclusivamente datos de mercado no confidenciales:

- **Activo:** SPY ETF.
- **Frecuencia:** datos intradía cada 5 minutos.
- **Datos base:** Open, High, Low, Close y Volume.

A partir de estos datos se construyen variables de estado como:

retornos, volatilidad, momentum, volumen relativo,

perfil de volumen, proxy de spread.

El estado observado por el agente puede representarse como:

$s_t = [\text{inventario restante}, \text{tiempo restante}, \text{estado del mercado}]$

mientras que la acción representa la fracción de la orden total ejecutada en cada instante:

$a_t = \text{fracción de ejecución.}$

3. Hipótesis: Reinforcement Learning

Hipótesis de investigación:

Un agente basado en **Deep Q-Network (DQN)** puede aprender una política de ejecución dependiente del estado que adapte dinámicamente la intensidad de trading según el inventario restante y las condiciones intradía del mercado.

Una política clásica puede representarse conceptualmente como:

$$a_t = f(t, I_t)$$

mientras que el agente de Reinforcement Learning busca aprender:

$$a_t = \pi(s_t)$$

mediante una aproximación de la función de valor:

$$Q(s_t, a_t).$$

Modelos de referencia para contrastar la hipótesis:

- TWAP,
- VWAP-like,
- Volume Aware Almgren-Chris